

Material Auxiliar - Unidade 2  
Convergência Estocástica e Resultados Limite  
Explicações Detalhadas e Didáticas

Curso de Inferência Estatística

Outubro 2025

**Sumário**

# 1 Introdução

Este material auxiliar complementa as notas de aula da Unidade 2, fornecendo explicações mais detalhadas e didáticas dos principais conceitos abordados. O objetivo é facilitar a compreensão dos teoremas de convergência e suas aplicações práticas.

## 2 Notação $O(\cdot)$ e $o(\cdot)$ - Big O e Little o

### 2.1 Motivação e Intuição

A notação  $O(\cdot)$  e  $o(\cdot)$  é fundamental para descrever o comportamento assintótico de sequências e funções. Intuitivamente:

- $a_n = O(b_n)$ : " $a_n$  cresce *no máximo* tão rápido quanto  $b_n$ "
- $a_n = o(b_n)$ : " $a_n$  cresce *mais devagar* que  $b_n$ "

### 2.2 Definições Formais

**Definição 2.1** (Big O para sequências). Sejam  $\{a_n, n \geq 1\}$  e  $\{b_n, n \geq 1\}$  sequências de números reais. Dizemos que

$$a_n = O(b_n) \quad \text{se e somente se} \quad \exists k > 0, n_0 \in \mathbb{N} : \left| \frac{a_n}{b_n} \right| \leq k, \quad \forall n \geq n_0$$

Isto é, a razão  $|a_n/b_n|$  é limitada para  $n$  suficientemente grande.

**Definição 2.2** (Little o para sequências). Dizemos que

$$a_n = o(b_n) \quad \text{se e somente se} \quad \lim_{n \rightarrow \infty} \frac{a_n}{b_n} = 0$$

Isto é,  $a_n$  é desprezível comparado a  $b_n$  quando  $n$  é grande.

**Exemplo 2.1** (Comparações Comuns). 1.  $10n^2 + n = O(n^2)$  porque  $\frac{10n^2 + n}{n^2} = 10 + \frac{1}{n} \leq 11$  para  $n \geq 1$

2.  $n = o(n^2)$  porque  $\lim_{n \rightarrow \infty} \frac{n}{n^2} = \lim_{n \rightarrow \infty} \frac{1}{n} = 0$

3.  $\log(n) = o(n)$  porque  $\lim_{n \rightarrow \infty} \frac{\log(n)}{n} = 0$

4.  $n^{1/2} = O(n)$  mas  $n \neq O(n^{1/2})$

### 2.3 Propriedades Importantes

**Observação 2.1** (Álgebra de O e o). 1. Se  $a_n = o(b_n)$ , então  $a_n = O(b_n)$  (mas a recíproca é falsa)

2. Se  $a_n = O(b_n)$  e  $c_n = O(d_n)$ , então:

- $a_n \cdot c_n = O(b_n \cdot d_n)$
- $a_n + c_n = O(\max\{|b_n|, |d_n|\})$

3.  $O(1)$  significa limitado:  $|a_n| \leq k$  para algum  $k > 0$  e  $n$  grande

4.  $o(1)$  significa que  $a_n \rightarrow 0$

## 2.4 Aplicação em Séries de Taylor

A notação  $O(\cdot)$  é essencial para expressar aproximações via série de Taylor:

**Exemplo 2.2** (Série de Taylor). Para uma função  $F(x)$  derivável até ordem  $n$  em torno de  $x_0$ :

$$F(x) = \sum_{k=0}^n \frac{F^{(k)}(x_0)}{k!} (x - x_0)^k + o((x - x_0)^n)$$

quando  $x \rightarrow x_0$ .

Por exemplo:

- $e^x = 1 + x + \frac{x^2}{2} + O(x^3)$  quando  $x \rightarrow 0$
- $\log(1 + x) = x - \frac{x^2}{2} + O(x^3)$  quando  $x \rightarrow 0$

## 3 Convergência em Probabilidade

### 3.1 Intuição e Definição

A convergência em probabilidade expressa a ideia de que, à medida que  $n$  cresce, a probabilidade de  $U_n$  estar "longe" de  $u$  torna-se arbitrariamente pequena.

**Definição 3.1** (Convergência em Probabilidade). Uma sequência de variáveis aleatórias  $\{U_n, n \geq 1\}$  converge em probabilidade para um número  $u$  se

$$P(|U_n - u| \geq \varepsilon) \xrightarrow{n \rightarrow \infty} 0, \quad \forall \varepsilon > 0$$

Notação:  $U_n \xrightarrow{P} u$

### 3.2 Interpretação Prática

Pense em  $U_n$  como uma estimativa de  $u$  baseada em  $n$  observações. Convergência em probabilidade significa que:

- Com  $n$  grande, é *altamente improvável* que  $U_n$  esteja longe de  $u$
- Para qualquer margem de erro  $\varepsilon > 0$  que você escolha, a probabilidade de erro pode ser tornada arbitrariamente pequena aumentando  $n$

**Exemplo 3.1** (Média Amostral). Se  $X_1, X_2, \dots$  são v.a.'s i.i.d. com  $E[X_i] = \mu$  e  $\text{Var}(X_i) = \sigma^2 < \infty$ , então

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$$

Isso significa que a média amostral converge para a média populacional.

### 3.3 Métodos para Provar Convergência em Probabilidade

1. **Desigualdade de Chebyshev:** Se  $E[U_n] \rightarrow u$  e  $\text{Var}(U_n) \rightarrow 0$ , então  $U_n \xrightarrow{P} u$
2. **Convergência de momentos:** Se  $E[|U_n - u|^r] \rightarrow 0$  para algum  $r > 0$ , então  $U_n \xrightarrow{P} u$
3. **Função geradora de momentos:** Se  $M_{U_n}(t) \rightarrow e^{tu}$  para todo  $t$ , então  $U_n \xrightarrow{P} u$

### 3.4 Propriedades Algébricas

**Observação 3.1** (Álgebra da Convergência em Probabilidade). Se  $U_n \xrightarrow{P} u$  e  $V_n \xrightarrow{P} v$ , então:

1.  $U_n + V_n \xrightarrow{P} u + v$
2.  $U_n \cdot V_n \xrightarrow{P} u \cdot v$
3.  $\frac{U_n}{V_n} \xrightarrow{P} \frac{u}{v}$  (se  $P(V_n = 0) = 0$  e  $v \neq 0$ )
4. Se  $g(\cdot)$  é contínua, então  $g(U_n) \xrightarrow{P} g(u)$

## 4 Convergência em Distribuição

### 4.1 Definição e Diferenças

A convergência em distribuição é um conceito mais fraco que convergência em probabilidade.

**Definição 4.1** (Convergência em Distribuição). Uma sequência  $\{U_n, n \geq 1\}$  com f.d.a.  $F_n(u)$  converge em distribuição para uma v.a.  $U$  com f.d.a.  $F(u)$  se

$$F_n(u) \xrightarrow{n \rightarrow \infty} F(u)$$

em todos os pontos de continuidade de  $F(\cdot)$ .

Notação:  $U_n \xrightarrow{D} U$

### 4.2 Diferenças entre Convergências

- **Convergência em Probabilidade  $\Rightarrow$  Convergência em Distribuição**
- **Convergência em Distribuição  $\nRightarrow$  Convergência em Probabilidade** (em geral)
- **Exceção:** Se  $U_n \xrightarrow{D} c$  (constante), então  $U_n \xrightarrow{P} c$

**Exemplo 4.1** (Distinção Importante). Considere  $X \sim N(0, 1)$  e defina  $U_n = X$  para todo  $n$ . Então:

- $U_n \xrightarrow{D} X$  (trivialmente, pois  $F_n = F$  para todo  $n$ )
- $U_n \not\xrightarrow{P} X$  (não faz sentido:  $U_n - X = 0$  sempre!)

Agora considere  $U_n = (-1)^n X$ :

- $U_n \xrightarrow{D} X$  (ambos têm distribuição  $N(0, 1)$ )
- $U_n \not\xrightarrow{P} X$  (pois  $|U_n - X|$  não vai para zero)

## 4.3 Método da Função Geradora de Momentos

Um método poderoso para provar convergência em distribuição:

**Observação 4.1** (Teorema de Continuidade de Lévy). *Se  $M_{U_n}(t) \rightarrow M_U(t)$  para todo  $t$  em uma vizinhança de zero, então  $U_n \xrightarrow{D} U$ .*

Este método é frequentemente usado nas provas do TCL.

## 5 Lei Fraca dos Grandes Números

### 5.1 Versões e Interpretação

A Lei Fraca dos Grandes Números (LFGN) é um dos resultados fundamentais da probabilidade.

**Observação 5.1** (LFGN - Versão Simples). *Se  $X_1, \dots, X_n$  são v.a.'s i.i.d. com  $E[X_i] = \mu < \infty$  e  $\text{Var}(X_i) = \sigma^2 < \infty$ , então*

$$\bar{X}_n \xrightarrow{P} \mu$$

**Observação 5.2** (LFGN de Khinchin). *A condição de variância finita pode ser relaxada: basta  $E[X_i] = \mu < \infty$ .*

### 5.2 Interpretação Prática

- A média amostral é um estimador *consistente* da média populacional
- Quanto maior a amostra, mais confiável é a estimativa
- Justifica a "Lei dos Grandes Números" empírica: frequências relativas convergem para probabilidades

**Exemplo 5.1** (Lançamento de Moedas). Se  $X_i = 1$  (cara) ou  $X_i = 0$  (coroa) com  $P(X_i = 1) = p$ , então

$$\frac{\text{número de caras em } n \text{ lançamentos}}{n} = \bar{X}_n \xrightarrow{P} p$$

### 5.3 Aplicações

1. **Estimação de parâmetros:**  $\bar{X}_n$  estima  $\mu$ ,  $S_n^2$  estima  $\sigma^2$
2. **Simulação Monte Carlo:** Aproximar  $E[g(X)]$  por  $\frac{1}{n} \sum_{i=1}^n g(X_i)$
3. **Testes de hipóteses:** Proporções amostrais convergem para proporções populacionais

## 6 Teorema Central do Limite

### 6.1 Enunciado e Importância

O Teorema Central do Limite (TCL) é possivelmente o teorema mais importante da estatística.

**Observação 6.1** (TCL - Versão Clássica). *Se  $X_1, \dots, X_n$  são v.a.'s i.i.d. com  $E[X_i] = \mu$  e  $\text{Var}(X_i) = \sigma^2 < \infty$ , então*

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{D} N(0, 1)$$

### 6.2 Por Que é Tão Importante?

1. **Universalidade:** Funciona para *qualquer* distribuição com variância finita
2. **Base para inferência:** Justifica o uso da distribuição normal em intervalos de confiança e testes
3. **Aproximação prática:** Com  $n$  moderadamente grande ( $n \geq 30$ ),  $\bar{X}_n$  tem distribuição aproximadamente normal

### 6.3 Interpretação Geométrica

O TCL diz que:

- A distribuição de  $\bar{X}_n$  fica mais concentrada em torno de  $\mu$  (taxa  $1/\sqrt{n}$ )
- A forma da distribuição de  $\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$  converge para a curva normal
- Não importa a distribuição original dos  $X_i$ !

**Exemplo 6.1** (Distribuição Uniforme). Se  $X_i \sim U(0, 1)$  (distribuição uniforme), então  $E[X_i] = 1/2$  e  $\text{Var}(X_i) = 1/12$ .

$$\frac{\bar{X}_n - 1/2}{\sqrt{1/(12n)}} = \sqrt{12n} \left( \bar{X}_n - \frac{1}{2} \right) \xrightarrow{D} N(0, 1)$$

Embora  $X_i$  seja uniforme (nada parecido com normal),  $\bar{X}_n$  tem distribuição aproximadamente  $N(1/2, 1/(12n))$  para  $n$  grande.

### 6.4 Versões Padronizadas

- $\sigma$  conhecido:  $Z_n = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{D} N(0, 1)$
- $\sigma$  desconhecido:  $T_n = \frac{\sqrt{n}(\bar{X}_n - \mu)}{S_n} \xrightarrow{D} N(0, 1)$   
(onde  $S_n$  é o desvio padrão amostral)

## 7 Teorema de Slutsky

### 7.1 Enunciado e Utilidade

O Teorema de Slutsky permite combinar convergências de tipos diferentes.

**Observação 7.1** (Teorema de Slutsky). *Se  $U_n \xrightarrow{D} U$  e  $V_n \xrightarrow{P} c$  (constante), então:*

1.  $U_n + V_n \xrightarrow{D} U + c$
2.  $U_n \cdot V_n \xrightarrow{D} c \cdot U$
3.  $\frac{U_n}{V_n} \xrightarrow{D} \frac{U}{c}$  (se  $c \neq 0$ )

### 7.2 Por Que é Útil?

O teorema de Slutsky é crucial quando:

- Temos uma convergência em distribuição mas precisamos fazer operações algébricas
- Queremos substituir parâmetros desconhecidos por estimadores consistentes
- Provamos distribuições assintóticas de estatísticas de teste

**Exemplo 7.1** (Substituição do Desvio Padrão). Pelo TCL:  $\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{D} N(0, 1)$

Como  $S_n \xrightarrow{P} \sigma$ , pelo Slutsky:

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{S_n} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \cdot \frac{\sigma}{S_n} \xrightarrow{D} N(0, 1) \cdot 1 = N(0, 1)$$

Isso justifica usar  $S_n$  quando  $\sigma$  é desconhecido!

### 7.3 Aplicação em Testes de Hipóteses

O teorema de Slutsky permite construir estatísticas de teste quando parâmetros são desconhecidos, substituindo-os por estimadores consistentes sem alterar a distribuição assintótica.

## 8 Teorema de Mann-Wald (Método Delta)

### 8.1 Enunciado

O Método Delta é uma ferramenta para encontrar a distribuição assintótica de transformações de estimadores.

**Observação 8.1** (Teorema de Mann-Wald). *Se  $\sqrt{n}(T_n - \theta) \xrightarrow{D} N(0, \sigma^2(\theta))$  e  $g(\cdot)$  é uma função diferenciável com  $g'(\theta) \neq 0$ , então*

$$\sqrt{n}[g(T_n) - g(\theta)] \xrightarrow{D} N(0, \sigma^2(\theta) \cdot [g'(\theta)]^2)$$

## 8.2 Interpretação

O método delta diz que:

- Se  $T_n$  é aproximadamente normal com taxa  $1/\sqrt{n}$
- Então  $g(T_n)$  também é aproximadamente normal com taxa  $1/\sqrt{n}$
- A variância é "inflada" por  $[g'(\theta)]^2$

## 8.3 Ideia da Prova

A prova usa aproximação de Taylor de primeira ordem:

$$g(T_n) \approx g(\theta) + g'(\theta)(T_n - \theta)$$

Multiplicando por  $\sqrt{n}$ :

$$\sqrt{n}[g(T_n) - g(\theta)] \approx g'(\theta) \cdot \sqrt{n}(T_n - \theta)$$

Como  $\sqrt{n}(T_n - \theta) \xrightarrow{D} N(0, \sigma^2)$ , o resultado segue.

**Exemplo 8.1** (Transformação Logarítmica). Se  $\bar{X}_n$  estima  $\mu > 0$  e queremos estimar  $\log(\mu)$ , tome  $g(x) = \log(x)$ .

Como  $g'(x) = 1/x$ , temos:

$$\sqrt{n} [\log(\bar{X}_n) - \log(\mu)] \xrightarrow{D} N\left(0, \frac{\sigma^2}{\mu^2}\right)$$

**Exemplo 8.2** (Transformação de Variância). Para estimar a variância  $\sigma^2$ , usamos  $S_n^2$ . Se queremos estimar o desvio padrão  $\sigma = \sqrt{\sigma^2}$ , usamos  $g(x) = \sqrt{x}$  com  $g'(x) = \frac{1}{2\sqrt{x}}$ .

## 8.4 Aplicações Práticas

1. Transformações estabilizadoras de variância
2. Intervalos de confiança para funções de parâmetros
3. Testes de hipóteses sobre transformações
4. Modelos não-lineares

# 9 Resumo e Conexões

## 9.1 Hierarquia das Convergências

Convergência quase certa  $\Rightarrow$  Convergência em Probabilidade  $\Rightarrow$  Convergência em Distribuição



## 9.2 Teoremas Principais e Suas Relações

1. **LFGN:**  $\bar{X}_n \xrightarrow{P} \mu$  (onde está o valor)
2. **TCL:**  $\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{D} N(0, 1)$  (quão rápido chega lá e qual a forma da distribuição)
3. **Slutsky:** Permite combinações algébricas
4. **Método Delta:** Estende para transformações não-lineares

## 9.3 Estratégia de Resolução de Problemas

1. Identificar se  $T_n$  é uma média ou função de médias
2. Aplicar LFGN ou TCL conforme apropriado
3. Se há parâmetros desconhecidos, usar Slutsky para substituí-los
4. Se há transformação não-linear, usar Método Delta
5. Verificar condições (i.i.d., momentos finitos, etc.)